

Day 6 学习总结: CSV 文件 + pandas 数据处理

本节学习了用 **pandas** 处理表格数据，这是数据分析和 AI 工作中最常见的任务。

1. 什么是 CSV 文件

CSV = Comma-Separated Values (逗号分隔值)，是用逗号隔开的纯文本表格数据，可以用 Excel 打开。

```
姓名,语文,数学      ← 第一行是表头（列名）
小明,85,90          ← 之后每行是一条记录
小红,92,88
小刚,78,85
```

2. pandas 两个核心结构

结构	含义	类比
DataFrame	整张表格（有行有列）	Excel 表 / 二维数组
Series	表格里的一列	一维数组

3. 深入理解 Series（一列数据）

Series 就是 DataFrame 里的一列，是带行号的一维数据。你写 `df["语文"]` 得到的就是一个 Series：

```
0      85
1      92
2      78
Name: 语文, dtype: int64
```

- 左边 `0 1 2` 是索引（行号）
- 右边是值
- `Name: 语文` 是这列的名字
- `dtype: int64` 是数据类型（整数）

也可以单独创建一个 Series：

```
import pandas as pd

s = pd.Series([85, 92, 78])
print(s)
```

Series 常用方法: `s.mean()` 平均值、`s.max()` 最大值、`s.min()` 最小值、`s.sum()` 求和。

Series 和 DataFrame 的关系:
Series = 一列 (一维) ; DataFrame = 多个 Series 拼成的表格 (二维) 。
就像 C 语言里: 一维数组 vs 二维数组。

4. 核心操作速查表

操作	代码
导入 pandas	<code>import pandas as pd</code>
创建表格	<code>pd.DataFrame(dict)</code>
保存 CSV	<code>df.to_csv("文件.csv", index=False, encoding="utf-8-sig")</code>
读取 CSV	<code>pd.read_csv("文件.csv", encoding="utf-8-sig")</code>
取一列	<code>df["列名"]</code>
取多列	<code>df[["列1", "列2"]]</code>
筛选行	<code>df[df["列名"] > 值]</code>
行列同时筛	<code>df.loc[条件, "列名"]</code>
平均值	<code>df["列名"].mean()</code>
最大值	<code>df["列名"].max()</code>
排序 (降序)	<code>df.sort_values("列名", ascending=False)</code>
新增一列	<code>df["新列"] = df["A"] + df["B"]</code>
统计摘要	<code>df.describe()</code>

5. 第一个 pandas 程序

```
import pandas as pd

data = {
    "姓名": ["小明", "小红", "小刚"],
    "语文": [85, 92, 78],
    "数学": [90, 88, 85]
}

df = pd.DataFrame(data)
print(df)
```

6. 重点理解：布尔索引

`df["数学"] > 88` 不是直接筛行，而是先返回一列 True/False:

```
0    True    ← 90 > 88 是真
1   False
2   False
```

外面套 `df[...]` 的意思是「只保留 True 对应的行」：

```
df[df["数学"] > 88]    # 只留下数学大于88的行
```

对比 C 语言：

pandas 一行 `df[df["数学"] > 88]` 等价于 C 里写 for 循环 + if 判断逐行检查，但 pandas 不用写循环。

7. 找最高/最低值对应的行

错误写法（会报错）：`df.loc[df["总分"].max(), "姓名"]`

因为 `.max()` 返回的是数字（如 600000），被当成行号去找，找不到就报错。

正确写法（两步）：

```
最高分 = df["总分"].max()
print(df.loc[df["总分"] == 最高分, "姓名"])
```

8. 常见报错与注意点

问题	原因 / 解决
FileNotFoundError	当前目录没有该文件，检查文件名拼写和 cd 目录
KeyError: '列名'	列名拼错了，对照 DataFrame 里真实的列名
方法不生效 / TypeError	方法必须加括号： <code>.mean()</code> <code>.max()</code> <code>.describe()</code>
Excel 打开中文乱码	保存时用 <code>encoding="utf-8-sig"</code>
f-string 引号冲突	外层双引号，内层用单引号： <code>f"{df['列名']}"</code>

小贴士： `utf-8-sig` 比 `utf-8` 多了一个 BOM 标记，Windows 的 Excel 靠它识别 UTF-8 编码，避免中文乱码。有中文 + 要用 Excel 打开就用它。

9. 本节练习文件

- D:\pythonstudy\day6\pandas_basic.py (基础练习)
- D:\pythonstudy\day6\practice.py (综合练习)
- D:\pythonstudy\day6\homework.py (作业：商品销售数据分析)

Day 6 完成 · 下一步 Day 7：matplotlib 数据可视化